

Modelos Bionomiales

Modelos Estadísticos Avanzados

Santiago Benitez-Vieyra

Distribución Binomial.

1. Modelos para datos de presencia-ausencia.

Proceso de Bernoulli

serie de “experiencias” independientes donde la respuesta puede ser sólo de dos categorías.

- Es una respuesta binaria cualquier variable que pueda ser clasificada en sólo dos niveles: presencia/ausencia, categoría1/categoría2, morfo1/morfo2, ... en general éxito/fracaso.
- La media de una distribución binaria es igual a la probabilidad de ocurrencia de éxitos.
- La varianza de una distribución binaria es igual a la probabilidad de ocurrencia de éxitos por la probabilidad de ocurrencia de fracasos.

Proceso de Bernoulli

serie de experiencias independientes donde la respuesta puede ser sólo de dos categorías.

$$P(y = 1) = p$$

$$P(y = 0) = 1 - p$$

$$E(y) = p$$

Datos binomiales agrupados

- Cada respuesta está constituida por más de un proceso de Bernoulli.
- Aplican a datos de PROPORCIONES, en general conocemos el número de éxitos y el número total de procesos de Bernoulli por sujeto (fracasos = total – éxito).

$$E(y) = Np$$

La variable respuesta se distribuye como Binomial

$$Y_i \sim B(N, p)$$

El enlace canónico es logit

$$\eta = \log\left(\frac{\mu_i}{1 - \mu_i}\right)$$

Por lo que el valor esperado es igual al logit inverso.

$$\mu_i = \frac{e^\eta}{1 + e^\eta}$$

Colocando las variables predictoras en la parte sistemática...

$$\mu_i = \frac{e^{\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}}}{1 + e^{\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}}}$$

Chances (odds)

$$\text{logit}(p(y)) = \log \frac{p(y)}{1 - p(y)}$$

Donde $p(x)$ es la probabilidad de éxito y $1 - p(x)$ es la probabilidad de fracaso.


Chances (odds)


$$\log \frac{p(y)}{1 - p(y)} = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}$$

La respuesta es lineal en el espacio logit.

El cangrejo herradura







Análisis de la Devianza

```
fit <- glm(y ~ x, data = dat, family = binomial)
anova(fit, test = "Chisq")
```

Analysis of Deviance Table

Model: binomial, link: logit

Response: y

Terms added sequentially (first to last)

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			172	225.76	
x	1	31.306	171	194.45	2.204e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Test de cociente de verosimilitudes

```
fit0 <- glm(y ~ 1, data = dat, family = binomial)
fit1 <- glm(y ~ x, data = dat, family = binomial)
anova(fit0, fit1, test = "Chisq")
```

Analysis of Deviance Table

Model 1: y ~ 1

Model 2: y ~ x

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	172	225.76			
2	171	194.45	1	31.306	2.204e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interpretación de parámetros

```
exp(fit$coefficients)
```

(Intercept)	x
4.326214e-06	1.644162e+00

- La chance de tener éxito se incrementa 64.41% por cada unidad de aumento en la variable x.
- La probabilidad de tener éxito respecto a la probabilidad de no tenerlo se incrementa un 64.41%.
- El cociente de chances (odds ratio) es de 1.64 entre dos observaciones que difieran en una unidad.

La dosis letal 50%

- La dosis “letal” 50 toma su nombre de los ensayos de dosis-respuesta, en los cuales se aplica una dosis creciente de determinada droga y se examina una respuesta (que habitualmente es muerte/supervivencia).
- La LD50 indica el valor de la variable independiente a la cual obtenemos el mismo número de éxitos y de fracasos.

$$LD_{50} = -\beta_0 / \beta_1$$

Matriz de confusión

```
pred <- predict(fit, type = "response") #training or test?  
table(data = as.numeric(pred >= 0.5), reference = dat$y) #umbral
```


	reference	
data	0	1
0	27	16
1	35	95

ver también `confusionMatrix` del paquete `caret`

		<u>True class</u>			
		p	n		
<u>Hypothesized class</u>	Y	True Positives	False Positives	fp rate = $\frac{FP}{N}$	tp rate = $\frac{TP}{P}$
	N	False Negatives	True Negatives	precision = $\frac{TP}{TP+FP}$	recall = $\frac{TP}{P}$
Column totals:		P	N	accuracy = $\frac{TP+TN}{P+N}$	
				F-measure = $\frac{2}{1/\text{precision}+1/\text{recall}}$	

Fig. 1. Confusion matrix and common performance metrics calculated from it.

ROC y AUC



cada punto corresponde a una matriz de confusión con diferente umbral.

VER APP

Sobredispersión

- La sobredispersión es provocada por variación al azar **NO EXPLICADA** en la variable respuesta.
- Habitualmente se observa una importante devianza residual, que permanece incluso si se incorporan variables al modelo.
- Esta variabilidad provoca que la relación media-varianza esperada para la familia no se cumpla.
- Debe distinguirse de la sobredispersión aparente , debida a variables o interacciones faltantes, efectos no lineales no considerados, outliers en la variable respuesta o errores en la elección del enlace.

Uno de los supuestos de un MLG es que la variable dependiente se ajusta a una de las funciones de la familia exponencial. Cada una de estas familias está caracterizada por una relación media-varianza específica.

Distribución	Posición	Dispersión
Poisson	$E(Y) = \mu$	$var(Y) = \mu$
Binomial	$E(Y) = N\pi$	$var(Y) = N\pi(1 - \pi)$

Sin embargo, a veces la variabilidad observada es mayor en una proporción ϕ respecto a lo esperado. Si $\phi > 1$ entonces existe sobredispersión

Distribución	Posición	Dispersión
Poisson	$E(Y) = \mu$	$var(Y) = \phi\mu$
Binomial	$E(Y) = N\pi$	$var(Y) = \phi N\pi(1 - \pi)$

Veremos más sobre sobredispersión en la clase sobre modelos de conteos. Por lo pronto utilizaremos la estimación de $\phi > 2$ como límite para modelos sobredispersos.

Sólo los modelos binomiales agregados pueden tener sobredispersión. Ni los binarios ni modelos donde el modelo saturado esté en consideración pueden tenerla.

END